

Apêndice B

Diretrizes de avaliação

Apêndice do Capítulo 18

Brielen Madureira

Publicado em: 13/03/2024

B.1 Diretrizes de avaliação para um modelo de cinco estágios

CrITÉrios extraídos de (Cohen; Howe, 1988), traduzidos com substituição de “pesquisa” para “projeto”, de forma a torná-los mais genéricos, ou seja, se referir ao desenvolvimento de projetos em geral e não apenas aos de pesquisa em inteligência artificial.

AVALIANDO A TAREFA OU OBJETIVO DO PROJETO

1. A tarefa é significativa? Por quê?
 - Se o problema já foi definido antes, sua reformulação traz melhorias?
2. Há chances de seu projeto contribuir de forma significativa para o problema? A tarefa é manejável?
3. Conforme a tarefa se torna mais específica para seu projeto, ela ainda é representativa de uma classe de tarefas?
4. Algum aspecto interessante do problema foi simplificado ou abstraído?
 - Se o problema já estava previamente definido, algum aspecto dessa definição anterior foi abstraído ou simplificado?
5. Quais são os objetivos intermediários do projeto? Quais tarefas-chave serão ou já foram resolvidas como parte do projeto?
6. Como você saberá quando tiver demonstrado satisfatoriamente uma solução para o problema? É possível, para a tarefa em questão, demonstrar que se chegou a uma solução?

CRITÉRIOS PARA AVALIAÇÃO DE MÉTODOS

1. Que melhorias o método traz sobre tecnologias existentes?
 - Ele cobre mais situações (*input*)?
 - Ele produz mais variedade de comportamentos desejáveis (*outputs*)?
 - Espera-se que ele seja mais eficiente em termos de memória, velocidade, tempo de desenvolvimento, etc.?



- Ele é promissor para futuros desenvolvimentos (por exemplo, se um novo paradigma for introduzido)?
- 2. Há uma métrica já estabelecida para avaliar a performance do método (por exemplo, ela é normativa, tem validade cognitiva)?
- 3. O método depende de outros métodos? Ou seja, há necessidade de pré-processamento de dados, acesso a certas bases de conhecimento ou rotinas?
- 4. Quais são as premissas ou suposições necessárias?
- 5. Qual é o escopo do método?
 - Quão extensível ele é? Seria simples aumentar sua escala com uma base de conhecimento maior?
 - Como ele aborda a tarefa? E partes dela? E uma classe de tarefas?
 - Ele ou suas partes poderiam ser aplicados a outros problemas?
 - Ele é transferível para tarefas mais complicadas (talvez com mais conhecimento ou mais ou menos limitações ou com interações complexas)?
- 6. Quando o método não consegue dar uma boa resposta, ele se abstém, dá uma resposta ruim ou dá a melhor resposta possível dados os recursos disponíveis?
- 7. Quão bem esse método é compreendido?
 - Por que ele funciona?
 - Em quais circunstâncias ele não funciona?
 - As limitações são inerentes ao modelos ou simplesmente não foram tratadas?
 - As decisões de *design* estão bem justificadas?
- 8. Qual a relação entre o problema e o método? Por que ele funciona para esta tarefa específica?

CRITÉRIOS PARA AVALIAÇÃO DA IMPLEMENTAÇÃO DO MÉTODO

1. Quão demonstrativo é o programa?
 - Podemos avaliar seu comportamento externo?
 - Quão transparente ele é? Podemos avaliar seu comportamento interno?
 - A classe de habilidades necessárias para a tarefa pode ser demonstrada por um conjunto bem definido de casos de teste?
 - Quantos casos de teste ele demonstra?
2. Ele é refinado especialmente para um exemplo em particular?
3. Quão bem o programa implementa o método?
 - Você consegue determinar as limitações do programa?
 - Houve partes que foram deixadas de fora ou foram feitos quebra galhos? Por que e com qual efeito?
 - A implementação forçou uma definição detalhada ou mesmo uma re-avaliação do método? Como essa re-avaliação foi feita?
4. A performance do programa é previsível?



CRITÉRIOS PARA AVALIAÇÃO DO DESIGN DO EXPERIMENTO

1. Quantos exemplos podem ser demonstrados?
 - Eles são qualitativamente diferentes?
 - Esses exemplos ilustram todas as habilidades propostas? Eles ilustram limitações?
 - O número de exemplos é suficiente para justificar generalizações indutivas?
2. A performance do programa deve ser comparada com um *standard*, como um outro programa, *experts* ou novatos, com sua própria performance refinada? O *standard* deve ser normativo, ter validade cognitiva, basear-se em eventos do mundo real ou em simulações?
3. Quais são os critérios de uma boa performance? Quem os define?
4. O programa pode ser generalizado (ou seja, é independente do domínio)?
 - Ele pode ser testado em diversos domínios?
 - Os domínios são qualitativamente diferentes?
 - Eles representam uma classe de domínios?
 - A performance no domínio inicial deve ser comparada à performance em outros domínios? Você espera que o programa esteja customizado para ter uma performance melhor no(s) domínio(s) usado(s) para *debugging*?
 - O conjunto de domínios é suficiente para justificar uma generalização indutiva?
5. Uma série de programas relacionados está sendo avaliada?
 - Você consegue determinar como as diferenças entre os programas se manifestam em diferentes comportamentos?
 - Se o método foi implementado de forma distinta em cada programa da série, como essas diferenças afetam as generalizações?
 - Houve dificuldades na implementação do método em outros programas?

CRITÉRIOS PARA AVALIAÇÃO DOS ACHADOS DO EXPERIMENTO

1. Qual foi a performance do programa em comparação com o *standard* selecionado (por exemplo, outros programas, humanos, comportamento normativo)?
2. A performance do programa foi diferente das previsões de como o método deveria funcionar?
3. Quão eficiente é o programa em termos de requerimentos de memória e de conhecimento?
4. O programa demonstrou boa performance?
5. Você aprendeu o que você queria com o programa e os experimentos?
6. É fácil para os usuários entenderem-no?
7. Você consegue definir as limitações de performance do programa?
8. Você entende por que o programa funciona ou não funciona?



- Qual o impacto de mudanças sutis no programa?
- Sua performance está de acordo com o esperado em exemplos que não foram usados para *debugging*?
- O efeito de diferentes estratégias de controle pode ser determinado?
- Como o programa responde se o *input* é rearranjado, tem ruído ou está incompleto?
- Qual a relação entre as características dos problemas de teste e da performance (tanto externos, ou internos caso os registros do programa estejam disponíveis)?
- A compreensão do programa pode ser generalizada para o método? Para características do método? Para uma tarefa maior?

Referências

COHEN, P. R.; HOWE, A. E. *How Evaluation Guides AI Research: The Message Still Counts More than the Medium*. **AI Magazine**, v. 9, n. 4, p. 35, 1988.

