

por ela. Acontece que um modelo de língua não é capaz de preencher os requisitos relativos à autenticidade e veracidade das expressões que gera. De fato, trata-se de uma ferramenta incrível de geração de texto sendo usada para um fim para o qual não foi projetada. Como são capazes de gerar uma infinidade de expressões linguísticas, tem-se a impressão de que, de fato, têm domínio em várias áreas de conhecimento e tarefas. A consequência é que suas “alucinações” podem ser confundidas com novas “verdades”, oferecendo um risco enorme à sociedade, na medida em que a crença nessas verdades pode levar a comportamentos imprevisíveis. Percebe-se aí o perigo de se utilizar um sistema impróprio como se fosse um “gerador de conhecimento”.

Tão logo foi disponibilizado o ChatGPT, em 2022, as consequências desse cenário têm sido discutidas por vários setores das sociedades em todo o mundo, incluindo o Brasil. Já se prevê mudanças no trabalho em toda sorte de setores que usam informações para tomada de decisão, bem como aqueles que têm a redação de textos como atividade relevante. Incluem-se, portanto, o jornalismo, a educação formal, a pesquisa, o direito, apenas para citar alguns.

Se mal gerenciadas, essas transformações do mercado de trabalho podem ter custos econômicos e sociais significativos. Segundo a OECD (2023), 27% dos empregos podem ser impactados por automação com tecnologias de IA, e com o advento dos modelos generativos, certamente esses impactos aumentarão, para uma ampla gama de categorias de empregos. Para melhor proteção dos trabalhadores nos próximos anos, a OECD (2023) recomenda, entre outras medidas, que os governos garantam treinamento para lidar com a IA. A UNESCO (UNESCO, 2019) também enfatiza a necessidade de desenvolvimento de valores e habilidades para a vida e para o trabalho na era da IA e recomenda medidas para melhorar a literacia em IA em todas as camadas da sociedade. Capacitar a população com habilidades relacionadas à IA pode melhorar sua empregabilidade e prepará-los para as demandas deste mercado de trabalho em constante evolução. Além disso, compreendemos ser muito importante iniciativas para ampliar a educação em IA para públicos sub-representados em um esforço para aumentar a diversidade da força de trabalho.

Temos testemunhado que sociedades cada vez mais tecnológicas suscitam muitas questões de natureza ética. A velocidade com que os sistemas computacionais evoluem – em especial, os ditos inteligentes – tem nos mostrado que precisamos nos antecipar, de alguma forma, aos riscos que eles podem representar. Para alcançarmos desenvolvimento e utilização ética e responsável de sistemas de IA, precisamos contar com esforços coletivos e transdisciplinares, além de um diálogo constante entre governo, empresas, cientistas, especialistas e sociedade em geral. Nesse sentido, é fundamental promover debates mais amplos e plurais sobre os impactos dessas novas tecnologias, a fim de pensarmos de forma conjunta aplicações positivas dessas ferramentas em nossa sociedade.

Referências

AI and Ethics. Springer, 2023. Disponível em: <<https://link.springer.com/journal/43681/volumes-and-issues>>. Acesso em: 7 abr. 2023

ALISSON, S. **Their god is not our god.** Disponível em: <https://www.thecontinent.org/_files/ugd/287178_73f3d2af22614e678f277b631a62e491.pdf>. Acesso em: 11 jun. 2023.

Artificial intelligence and human rights. 1. ed. [s.l.] Dykinson, S.L., 2021.



BENDER, E. M. **The Power of Linguistics - Unpacking Natural Language Processing Ethics with Emily M. Bender.** [Podcast]. Disponível em: <<https://www.radicalai.org/e16-emily-bender>>. Acesso em: 7 abr. 2023.

BENDER, E. M. et al. **On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?** . Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency. **Anais...**: FAccT '21. New York, NY, USA: Association for Computing Machinery, 2021. Disponível em: <<https://doi.org/10.1145/3442188.3445922>>

BENDER, E. M. **You Are Not a Parrot And a chatbot is not a human. And a linguist named Emily M. Bender is very worried what will happen when we forget this.** Disponível em: <<https://nymag.com/intelligencer/article/ai-artificial-intelligence-chatbots-emily-m-bender.html>>. Acesso em: 9 abr. 2023.

BUOLAMWINI, J.; GEBRU, T. **Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification.** (S. A. Friedler, C. Wilson, Eds.) Proceedings of the 1st Conference on Fairness, Accountability and Transparency. **Anais...**: Proceedings of Machine Learning Research. PMLR, 2018. Disponível em: <<https://proceedings.mlr.press/v81/buolamwini18a.html>>

CAVALIERE, P.; ROMEO, G. **From Poisons to Antidotes: Algorithms as Democracy Boosters.** **European Journal of Risk Regulation**, v. 13, n. 3, p. 421–442, 2022.

CHANDRAN, R. **Indigenous groups in NZ, US fear colonisation as AI learns their languages.** Disponível em: <<https://www.context.news/ai/nz-us-indigenous-fear-colonisation-as-bots-learn-their-languages>>. Acesso em: 7 abr. 2023.

COECKELBERGH, M. **Artificial Intelligence, Responsibility Attribution, and a Relational Justification of Explainability.** **Science and Engineering Ethics**, v. 26, p. 2051–2068, 2020.

COMMISSION, E. **Proposal for a Regulation laying down harmonised rules on artificial intelligence.** Disponível em: <<https://digital-strategy.ec.europa.eu/en/library/proposal-regulation-laying-down-harmonised-rules-artificial-intelligence>>. Acesso em: 28 ago. 2023.

CORRÊA, N. K. et al. **Worldwide AI ethics: A review of 200 guidelines and recommendations for AI governance.** **Patterns**, v. 4, n. 10, p. 100857, 2023.

CRUZ, B. S. **Concessionária do Metrô de SP é processada por ter câmeras que leem nossas emoções.** Disponível em: <<https://www.uol.com.br/tilt/noticias/redacao/2018/08/31/concessionaria-do-metro-de-sp-e-processada-por-ter-cameras-que-leem-emocoes.htm>>. Acesso em: 29 ago. 2023.

CRUZ, B. S. **Racismo Calculado.** Disponível em: <<https://www.uol.com.br/tilt/reportagens-especiais/como-os-algoritmos-espalham-racismo/#cover>>. Acesso em: 29 ago. 2023.

EMPOLI, G. DA. **Os engenheiros do caos: Como as fake news, as teorias da**



conspiração e os algoritmos estão sendo utilizados para disseminar ódio, medo e influenciar eleições. [s.l.] Vestígio Editora, 2019.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [s.l.] MIT Press, 2016. v. 1

HALLIDAY, M. A. K.; MATTHIESSEN, C. M. I. M. **Construing Experience Through Meaning: A Language Based Approach to Cognition**. [s.l.] Continuum, 1999.

HEIKKILÄ, M. **Why you shouldn't trust AI search engines**. Disponível em: <<https://www.technologyreview.com/2023/02/14/1068498/why-you-shouldnt-trust-ai-search-engines/>>. Acesso em: 9 abr. 2023.

HEIKKILÄ, M. **The viral AI avatar app Lensa undressed me—without my consent**. Disponível em: <<https://www.technologyreview.com/2022/12/12/1064751/the-viral-ai-avatar-app-lensa-undressed-me-without-my-consent/>>. Acesso em: 28 ago. 2023.

HORA, N. DA. **Coded Bias: linguagem acessível para entender vieses em algoritmos**. Disponível em: <<https://mittechreview.com.br/coded-bias-linguagem-acessivel-para-entender-vieses-em-algoritmos/>>. Acesso em: 7 abr. 2023.

HORA, N. DA. **Ética em IA: a pergunta que não estamos fazendo**. Disponível em: <<https://mittechreview.com.br/etica-em-ia-a-pergunta-que-nao-estamos-fazendo/>>. Acesso em: 7 abr. 2023.

INFOBASE. **Inteligência Artificial e a perpetuação do racismo**. Disponível em: <<https://infobase.com.br/inteligencia-artificial-e-a-perpetuacao-do-racismo/>>. Acesso em: 28 ago. 2023.

KANTAYYA, S. **Coded Bias**. Disponível em: <<https://www.codedbias.com>>. Acesso em: 7 abr. 2023.

LGPD. **Lei Geral de Proteção de Dados Pessoais (LGPD)**. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm>. Acesso em: 9 abr. 2023.

NUNES, P. **LEVANTAMENTO REVELA QUE 90,5% DOS PRESOS POR MONITORAMENTO FACIAL NO BRASIL SÃO NEGROS**. Disponível em: <<https://www.intercept.com.br/2019/11/21/presos-monitoramento-facial-brasil-negros/>>. Acesso em: 28 ago. 2023.

O'NEIL, C. **Algoritmos de Destruição em Massa**. [s.l.] Editora Rua do Sabão, 2021.

OECD. **The OECD Framework for the Classification of AI systems**. Disponível em: <<https://wp.oecd.ai/app/uploads/2022/02/Classification-2-pager-1.pdf>>. Acesso em: 28 ago. 2023.

OECD. **OECD Employment Outlook 2023**. [s.l: s.n.]. p. 267



OPENAI. **ChatGPT: OpenA’s conversational AI model**. Disponível em: <<https://openai.com/blog/chatgpt/>>. Acesso em: 7 abr. 2023.

PERRIGO, B. Disponível em: <<https://time.com/6247678/openai-chatgpt-kenya-workers/>>. Acesso em: 9 abr. 2023.

REVIEW, M. T. **Um aplicativo de Inteligência Artificial que “desnudava” mulheres mostra como as deepfakes prejudicam os mais vulneráveis**. Disponível em: <<https://mittechreview.com.br/um-aplicativo-de-inteligencia-artificial-que-desnudava-mulheres-mostra-como-as-deepfakes-prejudicam-os-mais-vulneraveis/>>. Acesso em: 28 ago. 2023.

RUSSEL, S. **Human Compatible Artificial Intelligence and the Problem of Control**. [s.l.] Penguin Books, 2019.

SARTORI, L.; THEODOROU, A. **A Sociotechnical Perspective for the Future of AI: Narratives, Inequalities, and Human Control**. *Ethics and Inf. Technol.*, v. 24, n. 1, mar. 2022.

SMITH, G.; RUSTAGI, I. **Mitigating Bias in Artificial Intelligence: An Equity Fluent Leadership Playbook**. [s.l.] Berkeley Haas Center for Equity, Gender; Leadership, 2020.

UNESCO. **Beijing consensus on artificial intelligence and education**. UNESCO Paris, 2019.

UNESCO, D. G. **Recomendação sobre a Ética da Inteligência Artificial**. Disponível em: <https://unesdoc.unesco.org/ark:/48223/pf0000381137_por>. Acesso em: 28 ago. 2023.

UNICEF. **Declaração Universal dos Direitos Humanos**. Disponível em: <<https://www.unicef.org/brazil/declaracao-universal-dos-direitos-humanos>>. Acesso em: 28 ago. 2023.



Capítulo 21

E agora, PLN?

Maria das Graças Volpe Nunes

Helena de Medeiros Caseli

Publicado em: 26/09/2023

Atualizado em: 13/04/2026

Neste último Capítulo elencamos alguns desafios e perspectivas para o PLN em língua portuguesa e finalizamos com uma discussão sobre os limites atuais do PLN.

21.1 Desafios e perspectivas para o PLN-Português

Por razões históricas e econômicas, os sistemas atuais de PLN “estado da arte” são muito mais comuns em inglês do que em qualquer outra língua. Enquanto que outras comunidades têm adaptado para suas línguas os sistemas originalmente criados para o inglês (por meio de novos treinamentos, mas com aproveitamento de parâmetros), comunidades linguísticas minoritárias e comunidades linguísticas de países menos desenvolvidos são invisibilizadas no mundo digital, com consequências negativas e diretas na sua economia e desenvolvimento.

A comunidade de falantes do português no mundo é estimada, em 2025, em cerca de 300 milhões de pessoas (3,7% da população mundial) sendo o quinto idioma mais usado, depois do inglês, mandarim, hindi e espanhol. Contudo, essa representatividade não é contemplada no estado da arte da ciência, que está majoritariamente nas mãos de instituições e organizações não falantes do português. Pesquisadores brasileiros e portugueses têm levantado a necessidade de unir forças para colocar o português no lugar de destaque que ele merece¹.

O processamento do português brasileiro tem avançado de maneira consistente desde meados da década de 1990, principalmente a partir do uso de AM e de abordagens *cross-language* e multilíngue, que facilitam a construção rápida de recursos e soluções, e permitem a geração de uma aplicação em uma língua a partir de uma aplicação em outra língua. Mas ainda é precária a união de esforços entre os países da Comunidade de Países de Língua Portuguesa (CPLP), que inclui Portugal, Angola, Moçambique, Cabo Verde, Guiné-Bissau, São Tomé e Príncipe, além do Brasil. Se as diferenças linguísticas entre os diferentes idiomas representam barreiras para a criação de sistemas comuns, não há dúvida de que a união de esforços trará benefícios para todos. Por ora, o esforço mais visível é aquele entre os mais fortes do grupo, Brasil e Portugal, que realizam um evento científico bianual comum, o PROPOR², e mantêm vínculos acadêmicos há várias décadas. No Brasil, os recursos de PLN compartilhados pela comunidade distribuem-se pelos centros de pesquisa,

¹<https://www.publico.pt/2023/02/09/opiniao/opiniao/lingua-portuguesa-tecnologia-futuro-2038078>

²CE-PLN. PROPOR (*International Conference on Computational Processing of Portuguese Language*). Disponível em: <https://sites.google.com/view/ce-pln/eventos/propor>.



sendo dois exemplos o NILC³ e o C4AI⁴. Em Portugal, dois importantes repositórios de recursos e ferramentas para português europeu e brasileiro são a Linguateca⁵ e o Portulan Clarin⁶.

Em países extensos como o Brasil, onde há uma grande variedade linguística, a exemplo das diferentes línguas indígenas faladas em território nacional⁷, das variações dialetais e sociais e dos sotaques regionais do português brasileiro, suas riquezas e diversidades linguísticas dificilmente são representadas nos *corpora*. Essa sub-representação nos dados de treinamento de modelos de aprendizado de máquina é um dos fatores que contribuem para aumentar a codificação de vieses por esses sistemas. Percebe-se, portanto, a importância de os dados linguísticos que alimentam tais sistemas serem coletados de forma responsável, buscando representar as variações linguísticas e idiomáticas das línguas faladas no país.

Um dos primeiros *corpora* em português brasileiro usado para treinar um modelo de língua é o BrWac (*Brazilian Portuguese Web as corpus*), composto por 3,53 milhões de documentos da web, totalizando 2,68 bilhões de *tokens*, com acesso público para pesquisadores⁸. Já o *corpus* Carolina, do Centro de IA, C4AI⁹, é, de acordo com os autores, “um *corpus* com um volume robusto de textos em Português Brasileiro contemporâneo (1970-2021), com informações de procedência e tipologia. O *corpus* está disponível em acesso aberto, para download gratuito, desde 8 de março de 2022. A versão atual, Ada 1.2 (8 de março de 2023), tem 823 milhões de *tokens*, mais de dois milhões de textos e mais de 11 GBs”. Esse *corpus* é um importante passo para o treinamento de LLM do português brasileiro, e tem o mérito de incluir uma grande variedade de gêneros (jornalismo, literatura, poesia, judiciário, wikis, mídia social, legislativo, acadêmico etc.). Já na área de língua falada, o projeto TaRSila¹⁰ tem como meta a construção de *datasets* robustos para o alcance de resultados no estado da arte para tarefas de reconhecimento e síntese de fala, identificação do falante e clonagem de voz. Destacamos o grande e multipropósito *corpus* de áudios, CORAA¹¹, alinhado com transcrições e manualmente validado para o treinamento de modelos de reconhecimento e síntese, bem como de análise de sentimentos usando características acústicas.

Na linha dos recursos para estimular o desenvolvimento aberto da IA generativa em português, em 2025, foram apresentados o GigaVerbo, uma concatenação de *corpora* de texto desduplicados em português, totalizando 200 bilhões de *tokens*, e o Tucano, uma série de *decoder-transformers* pré-treinados em português. A descrição completa desses recursos está em (Corrêa et al., 2025), e o código-fonte usado para treinamento e avaliação, entre outros subprodutos do estudo, está disponível no [GitHub](#) e no [Huggin Faece](#).

No mesmo C4AI, o projeto PROINDL¹², em parceria com comunidades indígenas, investe no uso da IA para o desenvolvimento de ferramentas que promovam a preservação, revitalização e disseminação de línguas indígenas do Brasil. Entre as técnicas usadas estão as de AM que utilizam poucos dados para criar tradutores automáticos tanto para texto como para fala, além de outras aplicações.

³<https://sites.google.com/view/nilc-usp/resources-and-tools>

⁴https://c4ai.inova.usp.br/pt/pesquisas_2/#NLP2_B_eng

⁵<https://www.linguateca.pt/>

⁶<https://portulanclarin.net/>

⁷<https://www.gov.br/funai/pt-br/assuntos/noticias/2022-02/brasil-registra-274-linguas-indigenas-diferentes-faladas-por-305-etnias>

⁸<https://www.inf.ufgrs.br/pln/wiki/index.php?title=BrWaC>

⁹<https://sites.usp.br/corpuscarolina/>

¹⁰TaRSila. Disponível em: <https://sites.google.com/view/tarsila-c4ai>.

¹¹<https://sites.google.com/view/tarsila-c4ai/coraa-versions>

¹²<https://conexoesoriginarias.github.io/>

